

Segmentasi Pendekatan Deep Learning


Agus Harjoko

1

Segmentation types

- Cara model menangani kelas objek (kategori) dan identitas individu (*instance*) dari setiap objek.

- Semantic segmentation
- Instance segmentation
- Panoptic segmentation



2


Semantic Segmentation

- Mengelompokkan setiap piksel dalam citra ke dalam kelas atau kategori tertentu (seperti *manusia, mobil, jalan, pohon*).
- **Karakteristik Utama:** Tidak membedakan individu dari kelas yang sama.
 - Jika ada tiga mobil bersebelahan, seluruh piksel ketiga mobil tersebut akan diberi label yang sama (misal: "mobil").
- **Fokus:** Mengidentifikasi "**apa**" kategori objek di setiap piksel.
- **Tipe Objek:** Mengolah objek yang terdefinisi (*things*) maupun latar belakang/area luas (*stuff*).

3

Instance Segmentation

- Instance segmentation menggabungkan tugas *object detection* (deteksi lokasi objek) dan *semantic segmentation*. Model mengidentifikasi dan memisahkan setiap objek dari kelas yang sama.
- **Karakteristik Utama:** Membedakan setiap individu objek secara spesifik.
 - Jika ada tiga mobil, model akan memberi label unik untuk masing-masing mobil (*mobil 1, mobil 2, mobil 3*).
- **Fokus:** Mengidentifikasi "**siapa/mana**" individu objek secara spesifik.
- **Tipe Objek:**
 - Hanya berfokus pada objek terhitung yang memiliki bentuk terdefinisi (*things*), seperti manusia, kendaraan, atau hewan.
 - Piksel latar belakang (seperti langit, jalan, atau rumput) biasanya **diabaikan** (dianggap sebagai *background*).



4

Panoptic Segmentation

- Gabungan (*unifikasi*) dari **Semantic Segmentation** dan **Instance Segmentation**.
 - Memberikan pemahaman konteks visual secara utuh dan menyeluruh pada seluruh citra.
- **Karakteristik Utama:** Setiap piksel dalam citra wajib diberi label kategori **sekali** label identitas individu (jika piksel tersebut milik objek *instance*).
- **Fokus:** Memahami **seluruh isi citra secara konseptual dan individual tanpa ada piksel yang terlewat**.
- **Tipe Objek:** Memproses objek terhitung (*things*) dengan identitas individu, sekaligus memetakan area latar belakang/tekstur (*stuff*) secara semantik.

5

Ilustrasi

Bayangkan sebuah foto yang memperlihatkan **3 orang berjalan di atas trotoar dengan latar belakang gedung**:

- **Semantic:** Menandai piksel orang dengan warna *merah* (gabungan 3 orang jadi 1 bentuk merah besar), trotoar warna *biru*, dan gedung warna *Hijau*.
- **Instance:** Menandai Orang 1 warna *merah*, Orang 2 warna *kuning*, dan Orang 3 warna *merah muda*. Trotoar dan gedung **diabaikan / hitam**.
- **Panoptic:** Menandai Orang 1 warna *merah*, Orang 2 warna *kuning*, Orang 3 warna *merah muda*, trotoar warna *biru*, dan gedung warna *hijau*. Semua piksel terisi dan terpetakan sempurna.

6

Semantic, Instance, and Panoptic Segmentation

Fitur	Semantic Segmentation	Instance Segmentation	Panoptic Segmentation
Pemisahan Individu?	Tidak	Ya	Ya
Segmentasi Latar Belakang?	Ya	Tidak	Ya
Cakupan Piksel	Seluruh piksel citra	Hanya piksel objek (<i>things</i>)	Seluruh piksel citra
Kategori Objek	<i>Things & Stuff</i>	Hanya <i>Things</i>	<i>Things & Stuff</i>
Output Contoh	"Piksel ini adalah mobil"	"Piksel ini milik Mobil #2"	"Piksel ini milik Mobil #2 di atas Jalanan"

7

Segmentation Evaluation

- Pengukuran performa model segmentasi berfokus pada seberapa akurat area/piksel prediksi (*prediction*) berimpitan dengan label sebenarnya (*ground truth*).
- Kerangka dasar evaluasi ini umumnya dihitung menggunakan matriks konfusi tingkat piksel:
 - **True Positive (TP):** Piksel objek yang berhasil diprediksi dengan benar sebagai objek.
 - **False Positive (FP):** Piksel latar belakang yang salah diprediksi sebagai objek.
 - **False Negative (FN):** Piksel objek yang gagal terdeteksi oleh model.

8

Intersection over Union (IoU) / Jaccard Index

- IoU adalah metrik paling populer untuk mengukur kualitas segmentasi pada **Semantic Segmentation** (dan juga dipakai sebagai ambang batas/threshold pada Instance Segmentation).
- **Konsep dan Formula**
- IoU mengukur rasio antara luas area **irisan (intersection)** dan luas area **gabungan (union)** antara *ground truth* (A) dan area prediksi (B).

$$\text{IoU} = \frac{|A \cap B|}{|A \cup B|} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}}$$
- Nilai IoU berkisar antara **0** (tidak ada irisan sama sekali) hingga **1** (prediksi sempurna dan tepat melapisi ground truth).
- **Mean IoU (mIoU)**: Rata-rata nilai IoU yang dihitung untuk seluruh kelas objek dalam dataset.

9

Panoptic Quality (PQ)

- Dirancang khusus untuk mengukur performa Panoptic Segmentation. Karena segmentasi panoptik memadukan *stuff* (kategori area luas) dan *things* (objek individual), PQ menggabungkan evaluasi pengenalan objek (segmentasi instance) sekaligus kualitas batas pikselnya (segmentasi semantik).
- PQ membagi penilaian menjadi dua komponen utama: **Segmentation Quality (SQ)** dan **Recognition Quality (RQ)**.

$$\text{PQ} = \underbrace{\frac{\sum_{(p,g) \in \text{TP}} \text{IoU}(p, g)}{|\text{TP}|}}_{\text{Segmentation Quality (SQ)}} \times \underbrace{\frac{|\text{TP}|}{|\text{TP}| + \frac{1}{2}|\text{FP}| + \frac{1}{2}|\text{FN}|}}_{\text{Recognition Quality (RQ)}}$$

10

Panoptic Quality (2)

- **Segmentation Quality (SQ):** Mengukur seberapa presisi bentuk/tepi piksel dari objek-objek yang berhasil dideteksi dengan benar (TP). SQ menghitung **rata-rata IoU** dari seluruh pasangan prediksi (p) dan ground truth (g) yang cocok.
- **Recognition Quality (RQ):** Mengukur keberhasilan model dalam mendeteksi objek secara keseluruhan tanpa memedulikan prpiksel. Konsep RQ mirip dengan metrik F_1 -**Score** pada deteksi objek.
- **Syarat Match (TP):** Pasangan prediksi dan ground truth dianggap sebagai TP jika nilai $\text{IoU}(p, g) > 0.5$.

11

Metrik	Aplikasi	Keunggulan Utama
Dice Similarity Coefficient (DSC)	Semantic Segmentation	Sangat sensitif terhadap ketidakseimbangan kelas (<i>class imbalance</i>). DSC identik secara matematis dengan F_1 -Score tingkat piksel: $\frac{2TP}{2TP+FP+FN}$
Pixel Accuracy (PA)	Semantic Segmentation	Menghitung persentase piksel yang diprediksi benar dibanding total piksel. <i>Kurang ideal jika latar belakang sangat mendominasi.</i>
Average Precision (AP / mAP)	Instance Segmentation	Mengukur performa deteksi dan segmentasi mask tiap <i>instance</i> pada berbagai ambang batas IoU (misal mAP_{50} atau $\text{mAP}_{50:95}$).

12

Loss Functions

- *Loss function* pada segmentasi citra dirancang untuk mengukur seberapa jauh perbedaan antara peta prediksi piksel yang dihasilkan model (*predicted probability map*) dan label sebenarnya (*ground truth mask*).
- Pemilihan *loss function* sangat menentukan kestabilan pelatihan, terutama saat menghadapi masalah **ketidakseimbangan kelas (class imbalance)**, misalnya ketika objek yang ingin disegmentasi hanya berukuran beberapa piksel di tengah latar belakang yang sangat luas.

13

1. Pixel-wise Loss (Berbasis Piksel)

Fungsi rugi pada kategori ini mengevaluasi setiap piksel secara independen tanpa mempertimbangkan struktur atau konteks tetangganya.

A. Binary Cross-Entropy (BCE) Loss

- BCE mengukur perbedaan distribusi probabilitas antara prediksi (p_i) dan label ($y_i \in \{0,1\}$) pada setiap piksel i .

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

- **Kelebihan:** Konvergensi relatif stabil dan cepat pada dataset seimbang.
- **Kelemahan:** Sangat sensitif terhadap *class imbalance*. Jika 95% area gambar adalah latar belakang (*background*), model akan cenderung memprediksi semua piksel sebagai latar belakang karena tetap mendapatkan nilai loss yang kecil.

14

1. Pixel-wise Loss (Berbasis Piksel)

B. Focal Loss

- Dikembangkan untuk mengatasi ketidakseimbangan kelas pada deteksi objek dan segmentasi. Focal Loss memodifikasi BCE dengan menambahkan *modulating factor* $(1 - p_t)^\gamma$.

$$\mathcal{L}_{\text{Focal}} = -\alpha_t (1 - p_t)^\gamma \log(p_t)$$

- Prinsip Kerja:** Menurunkan bobot loss untuk piksel yang mudah diklasifikasikan (*easy examples/background*) dan memberi perhatian lebih pada piksel yang sulit diklasifikasikan (*hard examples/object boundaries*).
- Penggunaan:** Sangat cocok untuk segmentasi objek berukuran sangat kecil (seperti lesi kulit atau jaringan sel abnormal).

15

2. Overlap-based Loss (Berbasis Overlap / Area)

Fungsi rugi kategori ini mengevaluasi kemiripan bentuk (*shape similarity*) dan persentase irisan antara area prediksi dan *ground truth* secara keseluruhan.

A. Dice Loss

- Dice Loss diturunkan dari metrik *Dice Similarity Coefficient* (DSC). Loss ini menghitung rasio overlapping antara dua area.

$$\mathcal{L}_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N p_i y_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i + \epsilon}$$

- (Nilai ϵ atau *smooth factor* digunakan untuk mencegah pembagian dengan nol).
- Kelebihan:** Kebal terhadap masalah *class imbalance* karena loss hanya berfokus pada area irisan objek, bukan pada luas area latar belakang.
- Kelemahan:** Gradien bisa menjadi sangat tidak stabil saat proses pelatihan awal karena perubahan nilai prediksi kecil dapat mengubah skor Dice secara drastis.

16

2. Overlap-based Loss (Berbasis Overlap / Area)

B. IoU / Jaccard Loss

- Prinsipnya sangat mirip dengan Dice Loss, namun diturunkan langsung dari metrik *Intersection over Union* (IoU).

$$\mathcal{L}_{\text{IoU}} = 1 - \frac{\sum_{i=1}^N p_i y_i + \epsilon}{\sum_{i=1}^N p_i + \sum_{i=1}^N y_i - \sum_{i=1}^N p_i y_i + \epsilon}$$

17

3. Combined / Hybrid Loss (Kombinasi)

Mengombinasikan keunggulan stabilitas *pixel-wise loss* dengan kebal-imbalance milik *overlap loss*.

A. BCE-Dice Loss

- Mengkombinasikan BCE Loss dan Dice Loss secara linier:

$$\mathcal{L}_{\text{BCE-Dice}} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Dice}}$$

- Keunggulan:** BCE menjaga kestabilan gradien dan kelancaran optimasi di awal pelatihan, sementara Dice Loss memastikan bentuk objek disegmentasi secara akurat tanpa terganggu oleh besarnya latar belakang. Ini merupakan *loss function* standar untuk arsitektur seperti **U-Net**.

18

3. Combined / Hybrid Loss (Kombinasi)

B. Combo Loss / Focal-Dice Loss

- Menggabungkan **Focal Loss** dan **Dice Loss** untuk memberikan performa maksimal pada dataset medis atau citra satelit yang sangat timpang (*extreme class imbalance*).

19

Ringkasan Panduan Pemilihan Loss Function

Skenario Dataset	Rekomendasi Loss Function
Objek & Background Seimbang	BCE Loss atau Cross-Entropy Loss
Objek Kecil / Ketidakseimbangan Kelas	Focal Loss, Dice Loss, atau Tversky Loss
Segmentasi Medis (MRI, CT-Scan)	Combo Loss (BCE + Dice Loss)
Segmentasi Multiklas (Banyak Kelas)	Categorical Cross-Entropy + Dice Loss

20


Arsitektur

- Arsitektur deep learning untuk segmentasi citra dibagi berdasarkan jenis tugasnya:
 - **Semantic Segmentation** (mengelompokkan piksel berdasarkan kelas objek tanpa membedakan individu), dan
 - **Instance/Panoptic Segmentation** (membedakan tiap individu objek secara terpisah).

21

1. Fully Convolutional Networks (FCN)


- **Kategori:** Semantic Segmentation
- **Prinsip Utama:** Mengganti *fully connected layer* (pada model klasifikasi standar) dengan *convolutional layer* dan *upsampling* (deconvolution) untuk menghasilkan output peta prediksi seukuran citra asli.
- **Penggunaan Utama:** Pondasi dasar dari mayoritas arsitektur segmentasi citra modern.




22

2. U-Net (Encoder-Decoder)

- **Kategori:** Semantic Segmentation
- **Prinsip Utama:** Memiliki struktur simetris berbentuk huruf U.
 - **Encoder (Contracting Path):** Mengstraksi fitur kontekstual dan memperkecil resolusi spasial.
 - **Decoder (Expanding Path):** Memperbesar kembali resolusi fitur.
 - **Skip Connections:** Menghubungkan layer encoder langsung ke decoder untuk mempertahankan informasi spasial/detail tepi yang hilang selama proses kompresi.
- **Penggunaan Utama:** Citra medis (MRI, CT-scan, sel mikroskop) dan citra satelit.



23




3. SegNet

- **Kategori:** Semantic Segmentation
- **Prinsip Utama:** Mirip dengan struktur encoder-decoder U-Net, namun menggunakan *max-pooling indices* dari jalur encoder saat melakukan *upsampling* di jalur decoder. Pendekatan ini lebih hemat memori dibandingkan U-Net.
- **Penggunaan Utama:** Pemrosesan scene jalanan (*autonomous driving*) dan navigasi robot.


24

4. DeepLab Series (DeepLabv1, v2, v3, v3+)

- **Kategori:** Semantic Segmentation
- **Prinsip Utama:**
 - Menggunakan **Atrous Convolution (Dilated Convolution)** untuk memperluas *field of view* filter tanpa menambah jumlah parameter.
 - **Atrous Spatial Pyramid Pooling (ASPP)** memproses fitur pada berbagai skala spasial secara bersamaan.
- **Penggunaan Utama:** Segmentasi lanskap kompleks, pemisahan objek di latar belakang pada fotografi seluler.



25



5. Mask R-CNN


- **Kategori:** Instance Segmentation
- **Prinsip Utama:** Pengembangan dari Faster R-CNN (untuk *object detection*). Selain memprediksi *bounding box* dan kelas objek, Mask R-CNN menambahkan cabang paralel (*mask branch*) yang memprediksi *binary mask* untuk setiap objek yang terdeteksi. Menggunakan **RoIAlign** untuk mempertahankan presisi koordinat piksel.
- **Penggunaan Utama:** Penghitungan jumlah objek (*object counting*), pengenalan kendaraan/pejalan kaki terpisah, segmentasi sel individual.

26

6. Vision Transformer (ViT) & Model Berbasis Attention

- **Kategori:** Semantic & Instance Segmentation
- **Arsitektur Populer:** SETR (SEgmentation TRansformer), Swin Transformer, Mask2Former, dan SAM (Segment Anything Model).
- **Prinsip Utama:** Menggantikan atau mengombinasikan *Convolutional Layer* dengan mekanisme *Self-Attention*. Model dapat memahami hubungan antar-piksel dalam jarak jauh (*global context*) tanpa terbatas pada ukuran kernel konvolusi lokal.
- **Penggunaan Utama:** Segmentasi citra umum tingkat lanjut (*zero-shot segmentation*), analisis citra kompleks skala besar.


27



28

SWIN Transformer


[Swin Transformer](#) is a hierarchical vision transformer. Images are processed in patches and windowed self-attention is used to capture local information. These windows are shifted across the image to allow for cross-window connections, capturing global information more efficiently. This hierarchical approach with shifted windows allows the Swin Transformer to process images effectively at different scales and achieve linear computational complexity relative to image size, making it a versatile backbone for various vision tasks like image classification and object detection.



29

Mask2Former


- The Mask2Former model was proposed in [Masked-attention Mask Transformer for Universal Image Segmentation](#) by Bowen Cheng, Ishan Misra, Alexander G. Schwing, Alexander Kirillov, Rohit Girdhar. Mask2Former is a unified framework for panoptic, instance and semantic segmentation and features significant performance and efficiency improvements over [MaskFormer](#).



30

SAM (Segment Anything Model)

The Segment Anything Model (SAM) is Meta AI's promptable image segmentation system trained on 11 million images and over 1.1 billion masks, capable of zero-shot segmentation from prompts such as points, boxes, or text



31

Ringkasan Pemilihan Arsitektur

Arsitektur	Kekuatan Utama	Rekomendasi Kasus Penggunaan
U-Net	Presisi tinggi pada detail lokal & dataset terbatas	Citra Medis, Biomedis, Geospasial
DeepLabv3+	Sangat akurat dalam menangkap objek berbagai ukuran	Segmentasi Pemandangan Umum / Perkotaan
Mask R-CNN	Mampu memisahkan tiap individu objek	Tracking Objek, Hitung Jumlah Objek
SAM / Swin-T	Generalisasi kuat & memahami konteks global secara luas	Tugas segmentasi umum tanpa <i>fine-tuning</i> ketat

32

Panoptic Segmentation

- Arsitektur **Panoptic Segmentation** harus menyelesaikan dua tugas sekaligus: memetakan area latar belakang/tekstur (*stuff*, seperti jalan, langit, rumput) dan memisahkan setiap objek terhitung secara individual (*things*, seperti mobil, manusia, hewan).
- Secara umum, terdapat **tiga pendekatan utama** dalam merancang arsitektur panoptic segmentation:
 1. Pendekatan Berbasis Dua Cabang (Top-Down / Proposal-Based)
 2. Pendekatan Bottom-Up (Non-Proposal / Single-Shot)
 3. Pendekatan Unifikasi Berbasis Transformer (End-to-End)

33

1. Pendekatan Berbasis Dua Cabang (Top-Down / Proposal-Based)

- Pendekatan ini menggabungkan dua modul terpisah yang berjalan secara paralel di atas satu *backbone* pembuat fitur (*Feature Extractor*).
- **Contoh Arsitektur: Panoptic FPN**
- **Cara Kerja:**
 - **Shared Backbone:** Menggunakan CNN (misal: ResNet) dengan **FPN (Feature Pyramid Network)** untuk mengekstrak fitur multi-skala dari citra.
 - **Instance Branch:** Menggunakan mekanisme ala **Mask R-CNN** (Region Proposal Network + RoIAlign) untuk mendeteksi *bounding box* dan memprediksi *mask* untuk objek kategori *things*.
 - **Semantic Branch:** Menggunakan kepala konvolusi terpisah (ala FCN/U-Net) yang mengambil fitur multi-skala dari FPN untuk memprediksi kelas piksel kategori *stuff*.
 - **Panoptic Fusion:** Modul peleburan (*post-processing*) menggabungkan hasil dari kedua cabang. Jika ada tumpang tindih (*overlap*) antara *instance mask* dan *semantic mask*, logika resolusi konflik akan memprioritaskan prediksi *instance* dengan skor kepercayaan tertinggi.

34

2. Pendekatan Bottom-Up (Non-Proposal / Single-Shot)

- Pendekatan ini tidak menggunakan *bounding box proposal*, melainkan memprediksi kelas semantik dan mengelompokkan piksel (*clustering*) berdasarkan vektor jarak/pusat objek secara langsung.
- **Contoh Arsitektur: Panoptic-DeepLab, Panoptic Deeplite**
- **Cara Kerja:**
 - **Semantic Branch:** Menggunakan encoder-decoder kuat (seperti DeepLabv3+ dengan Atrous Spatial Pyramid Pooling) untuk memprediksi kelas semantik setiap piksel.
 - **Instance Branch:** Memprediksi dua hal secara bersamaan pada tingkat piksel:
 - **Center Prediction:** Peta panas (*heatmap*) lokasi titik pusat dari setiap objek.
 - **Offset Prediction:** Vektor jarak spasial dari setiap piksel objek menuju ke titik pusatnya.
 - **Group Clustering:** Piksel-piksel objek dikelompokkan ke titik pusat terdekatnya berdasarkan estimasi *offset*, lalu dipadukan dengan hasil prediksi semantik. Pendekatan ini jauh lebih cepat (cocok untuk pemrosesan *real-time*).

35

3. Pendekatan Unifikasi Berbasis Transformer (End-to-End)

- Pendekatan modern yang menghilangkan pemisahan kaku antara cabang *stuff* dan *things*. Arsitektur ini mengolah kedua tugas menggunakan mekanisme *Self-Attention* secara terpadu.
- **Contoh Arsitektur: Mask2Former, Panoptic SegFormer, MaX-DeepLab**
- **Cara Kerja:**
 - **Pixel Decoder:** Mengekstrak fitur peta piksel resolusi tinggi dari citra input.
 - **Transformer Decoder:** Menggunakan himpunan *object queries* (vektor yang dilatih untuk menangkap konsep "objek" atau "area").
 - **Masked Attention:** Mengarahkan perhatian (*attention*) model khusus pada area spesifik yang relevan untuk setiap *query*.
 - **Direct Mask Prediction:** Setiap *query* secara langsung memprediksi satu *binary mask* dan label kelasnya (apakah itu *instance* spesifik dari mobil, atau area rumput). Tidak memerlukan modul peleburan (*fusion*) yang rumit di akhir.


36

Ringkasan Perbandingan Arsitektur

Arsitektur	Pendekatan	Keunggulan Utama	Kelemahan
Panoptic FPN	Two-Branch / Top-Down	Akurasi tinggi pada <i>instance mask</i> , berbasis arsitektur teruji	Lambat karena modul <i>post-processing</i> (fusion) dan proposal box
Panoptic-DeepLab	Bottom-Up	Sangat cepat (efisien), fleksibel untuk <i>real-time execution</i>	Terkadang kurang presisi pada objek kecil yang saling berhimpitan
Mask2Former	Transformer (Unified)	State-of-the-art akurasi (PQ tinggi), satu arsitektur untuk semua jenis segmentasi	Membutuhkan komputasi dan memori GPU yang besar

37

SwinFPNMTL Architecture



38